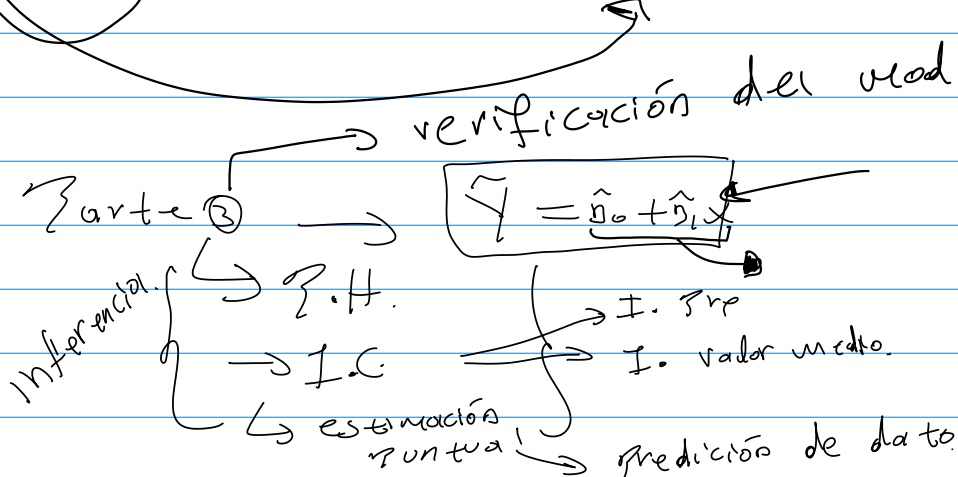



$$Y = \boxed{\beta_0 + \beta_1 X} + \epsilon_i$$

Diagram showing the components of the linear regression equation $Y = \beta_0 + \beta_1 X + \epsilon_i$. The equation is enclosed in a large rectangle. Inside, $\beta_0 + \beta_1 X$ is enclosed in a smaller rectangle labeled "parte ①". The error term ϵ_i is enclosed in another rectangle labeled "parte ③". Arrows point from the labels "parte ①", "parte ②", and "parte ③" to their respective parts in the equation.


parte ①
 ↳ hacemos inferencia

- P.H.
 - I.C.
 - estimación puntual
 - interpretaciones
- $\left. \begin{matrix} \beta_0 \\ \beta_1 \end{matrix} \right\} \text{coeficientes.}$



$R^2 \rightarrow$ Proporción de variabilidad explicada por el modelo

$$R^2 = \frac{SSR}{SST}$$



Parte teorica

1 Responder falso o verdadero y argumentar en caso de ser verdadero o dar un contra ejemplo en caso de ser falso

1.1 Un R^2 alto indica que el modelo puede hacer predicciones útiles. **F**

1.2 Un R^2 alto indica que la recta de regresión tiene buen ajuste. **F**

1.3 Un R^2 cercano a cero indica que X y Y no están relacionados. **F**

1.4 La formula del intervalo de predicción es:

Ojo
puede presentar relaciones cuadráticas y con $R^2 \approx 0$

1.4 La formula del intervalo de predicción es:

a) $\hat{y}_0 \pm t_{\alpha/2, n-2} \times \sqrt{\sigma^2 \left[\frac{1}{n} + \frac{(x_0 - \bar{x})^2}{S_{xx}} \right]}$

b) $\hat{y}_0 \pm t_{\alpha/2, n-5} \times \sqrt{\sigma^2 \left[\frac{1}{n} + \frac{(x_0 - \bar{x})^2}{S_{xx}} \right]}$

c) $\hat{y}_0 \pm t_{\alpha/2, n-2} \times \sqrt{\sigma^2 \left[1 + \frac{1}{n} + \frac{(x_0 - \bar{x})^2}{S_{xx}} \right]}$

d) $\hat{y}_0 \pm t_{\alpha/2, n-2} \times \sqrt{\sigma^2 \left[1 + \frac{1}{n} + \frac{(x_0 - \bar{x})^2}{S_{xx}} \right]}$

para la respuesta media

para un I. C de predicción.

Ojo

$$\sqrt{\sigma^2 \left[1 + \frac{1}{n} + \frac{(x_0 - \bar{x})^2}{S_{xx}} \right]}$$

1.5 Estimación puntual y por intervalo de la respuesta media $E[Y|x_0] + \varepsilon_0$ **F**

1.6 Predicción de valores futuros $y_0 = \beta_0 + \beta_1 x_0 = E[Y|x_0]$ **F**


Estimación para la respuesta media:

$$E(Y|x_0) = y_0 = \beta_0 + \beta_1 x_0$$

↓
respuesta media

Estimación para valores futuros

$$E(Y|x_0) = y_0 + \beta_0 + \beta_1 x_0 + \varepsilon_0$$



1) Sólo se podrán hacer inferencias sobre la respuesta cuando $X = x_0 \in [X_{\min}, X_{\max}]$, donde X_{\min} y X_{\max} son los valores mínimo y máximo de la variable predictora, que fueron fijados en la muestra. ☒ ☒

2 Completar la siguiente tabla anova.

Table 2: Tabla ANOVA parcialmente completada

Fuente de Variación	SS (Suma de Cuadrados)	df (Grados de Libertad)	MS (Cuadrado Medio)	F
Entre Grupos	10.25	1	$MSB = \frac{SSB}{1}$	$F_0 = \frac{MSB}{MSE}$
Dentro de Grupos	20.50	$n-1 = 28$	$MSE = \frac{SSE}{n-2}$	
Total	30.75	29		

$n =$

30

$$29 = n - 1$$


$$n = 30$$

$$MSB = 10.25$$

$$MSE = \frac{20.50}{28} = 0.7321$$

$$F_0 = \frac{10.25}{0.7321} = 14.00$$

$$\begin{cases} H_0: \beta_1 = 0 \\ H_a: \beta_1 \neq 0 \end{cases}$$



ubico en la $\alpha = 0.15$

Nota: cuando el F_0 es grande generalmente se rechaza H_0

fuente práctica

Punto 3

ϵ general.

$$Y_0 = \beta_0 + \beta_1 X + \epsilon_0, \epsilon_0 \sim N(0, \sigma^2)$$

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-41627.883	4889.428	-8.514	<2e-16 ***
train_data\$sqft_living	279.714	2.151	130.055	<2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

$$\hat{y} = -41627.883 + 279.714x$$

Modelo ajustado.

Punto ④

$$H_0: \beta_1 = 0$$



$$H_a: \beta_1 \neq 0$$

Pruebas de significancia para la pendiente

Pruebas de significancia para la regresión

$$t = \frac{\beta_0}{se(\beta_0)} \quad (\text{tabla de coeficientes})$$

$$F_0 = \frac{MSR}{MSE} \quad (\text{Anova})$$



$$H_0: \beta_1 = 0.$$

Prueba de
la significancia
para la
regresión

$$H_0: \beta_1 \neq 0$$

Prueba de
la significancia
para la
pendiente.

Analysis of Variance Table

Response: train_data\$price

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
train_data\$sqft_living	1	1.1427e+15	1.1427e+15	16914	2.2e-16 ***
Residuals	17288	1.1680e+15	6.7559e+10		

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

$F_0 = 16914$

$$V \neq \alpha.$$

→ rechazar H_0

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-41627.883	4889.428	-8.514	<2e-16 ***
train_data\$sqft_living	279.714	2.151	130.055	<2e-16 ***

$T = 130.055$

$$V \neq \alpha$$

→ rechazar H_0

Se rechaza H_0
por los dos
casos.

Nota: la prueba tipo t (pendiente)
es una prueba individual, es decir
valida la significancia de una sola
variable.

La prueba tipo f (anova) es una
prueba general, evalúa la significancia
general del modelo.

$$Y = \beta_0 + \boxed{\beta_1 X}$$

$$Y = \beta_0 + \boxed{\beta_1 X + \beta_2 X}$$

una sola prueba F

dos pruebas t y t

5. De una interpretación de los parámetros β_0 y β_1 del modelo, claro está, si es posible hacerlo.



Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-41627.883	4889.428	-8.514	<2e-16 ***
train_data\$sqft_living	279.714	2.151	130.055	<2e-16 ***

...

¿cómo mirar si β_0 es interpretable
necesitamos evaluar si el $X=0$ está
entre $(\min(X), \max(X))$

```
{r}
min(train_data$sqft_living)
max(train_data$sqft_living)
[1] 380
[1] 13540
```

β_0 no tiene interpretación.

B₁
↳

Por cada unidad de aumento en el área cuadrada habitable el promedio del precio de la propiedad cambia en 279.1

↓
B₁

```
Call:
lm(formula = train_data$price ~ train_data$sqft_living)

Residuals:
    Min       1Q   Median       3Q      Max
-1465693 -147174  -24984   106153  4371080

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)   -41627.883    4889.428   -8.514 <2e-16 ***
train_data$sqft_living    279.714      2.151  130.055 <2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 259900 on 17288 degrees of freedom
Multiple R-squared:  0.4945,    Adjusted R-squared:  0.4945
F-statistic: 1.691e+04 on 1 and 17288 DF, p-value: < 2.2e-16
```

R-squared = 0.4945

$$R^2 = \frac{SSR}{SST} = \frac{1.14 \times 10^{15}}{1.14 \times 10^{15} + 1.168 \times 10^{15}} \approx 0.4945$$

```
Analysis of Variance Table

Response: train_data$price
              Df Sum Sq Mean Sq F value Pr(>F)
train_data$sqft_living  1  1.1427e+15  1.1427e+15  16914 < 2.2e-16 ***
Residuals          17288  1.1680e+15  6.7559e+10
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

el modelo explica el 49.45% de la variabilidad total de la variable explicada